

# Видеодетекция как пространственно-временная задача

Современный подход к анализу видео требует понимания временной структуры данных и динамики объектов

# Природа детекции на видео

## Временная связь

Кадр связан с предыдущим и последующим состояниями сцены

## Скрытая динамика

Движение, освещение, позы определяют стабильность наблюдений

## Траектория

Истинная сущность объекта существует только в последовательности

Видеодетекция работает в пространстве, где наблюдение  $I_t$  — частная реализация процесса  $I(t)$ , который нельзя интерпретировать без временных зависимостей.

# Временная когерентность

Свойство детектора выдавать согласованные предсказания для последовательности кадров

$$|b_t - b_{t-1}| \leq \delta$$

## Дрейф (drift)

Ненадёжное изменение положения рамки при отсутствии изменений в сцене. Возникает из-за интерпретации шумов как значимых изменений.

## Накопление ошибок

В долгих видео накопленные ошибки становятся разрушительными — объект может «уплыть» из истинной позиции.

- ❏ Детекторы с высоким mAP на статичных датасетах могут показывать неудовлетворительную стабильность во временных приложениях

# Объекты меняются во времени



## Изменение позы

Человек меняет позу, создавая различные проекции одного объекта



## Перспективные искажения

Движение камеры создаёт искажения даже у жёстких объектов



## Масштаб и деформации

Объект в момент  $t$  и  $t+1$  выглядит по-разному, оставаясь той же сущностью

Проекция изменяется:  $I_t = \Pi(S(t))$ , где  $S(t)$  — истинная форма объекта. Детектор работает лишь с проекцией, теряя информацию о внутренней динамике.

# Дискретизация времени

Видео — дискретная последовательность с частотой fFPS

1

Ошибка дискретизации

$$\varepsilon(tk) = x(t) - x(tk)$$

2

Потеря производных

Скорость и ускорение теряются при  
сэмплинге

3

Компенсация

Фильтры движения в трекере  
восстанавливают динамику

При высоких скоростях движения детектор видит лишь далёкие друг от друга состояния без промежуточных данных

# Flicker-детекции и пропуски

## Природа мерцания

Объект то появляется, то исчезает в последовательности кадров

Последовательность confidence:

$ct, ct+1, ct+2, \dots$  флуктуирует около порога  $cthr$

- Детектор не использует прошлые кадры
- Шумы, освещение, ракурс влияют на confidence
- Случайные флуктуации неотличимы от исчезновения

## Последствия

Для трекинга критичны:

- Разрывы траекторий
- Рост ID-switch
- Сложные эвристики реактивации



Видеодетекция без трекинга  
непригодна для реальных задач  
мониторинга

# Формализация видеодетекции

Задача нахождения функции, отображающей последовательность кадров в множество детекций:

$$D : I_1, I_2, \dots, I_T \rightarrow \{B_t\}_{t=1}^T$$

01

Входные данные

$I_t$  — кадры видеоряда

02

Выходные данные

$B_t$  — множество детекций (координаты, класс, confidence)

03

Скрытое состояние

$x_t = (u_t, v_t, s_t, u_t^i, v_t^i, s_t^i)$

04

Наблюдение

$z_t = Hx_t + \eta_t$

Большинство моделей используют лишь  $I_t$ , игнорируя временную историю, что приводит к нестабильности

# Влияние FPS, latency и stride



## Частота кадров

Максимальное смещение:

$$\Delta x_{max} \approx \frac{v}{f_{FPS}}$$

Чем ниже FPS, тем выше  
вероятность потери объекта



## Задержка (latency)

Задержка  $t$  между появлением  
кадра и результатом приводит к  
систематическому сдвигу  
траекторий



## Stride

Пропуск кадров увеличивает  
расстояние между наблюдениями,  
приводя к нелинейному росту  
ошибок



# Ограничения однофреймовых моделей

Детекторы без механизма памяти не способны:

- |                          |                                                                            |                          |                                                                              |
|--------------------------|----------------------------------------------------------------------------|--------------------------|------------------------------------------------------------------------------|
| <input type="checkbox"/> | Определять динамику<br>Скорость и направление движения объектов недоступны | <input type="checkbox"/> | Компенсировать пропуски<br>Кратковременные исчезновения не восстанавливаются |
| <input type="checkbox"/> | Устранять флуктуации<br>Временные колебания confidence не сглаживаются     | <input type="checkbox"/> | Поддерживать идентичность<br>Согласованность объектов во времени отсутствует |

Формально:  $P(B_t | I_t)$  вместо  $P(B_t | I_{1:t})$

# Tracking-by-detection

## Парадигма

Детектор работает независимо на каждом кадре, трекер выполняет ассоциацию детекций между кадрами


Задача трекера — построить множество треков:

$$T = \{(b_{t_1}^i, b_{t_2}^i, \dots) \forall i\}$$

## Преимущества

- Комбинация мощных статических детекторов
- Лёгкие алгоритмы ассоциации
- Фильтр Калмана + венгерский алгоритм
- Стандарт индустрии

# Переход к видеоархитектурам



# Современные детекторы



## RetinaNet

Anchor-based подход с Focal Loss для борьбы с дисбалансом классов



## YOLO v5-v8

Высокая скорость, real-time inference, активное применение в видеонаблюдении



## DINO-DETR

Трансформерный декодер, улучшенная сходимость, глобальный контекст



## RT-DETR

Оптимизация трансформерного стека под real-time режим

Детекторы оптимизированы под статичное изображение, но служат фундаментом для видеосистем

# Как детекторы видят объект во времени

Однофреймовый детектор не хранит памяти от кадра к кадру

## Отсутствие связи

Результат детектора:

$$b_t = f(I_t)$$

Производная по времени:

$$\Delta b_t = b_t - b_{t-1}$$

не контролируется моделью

## Парадокс точности

Детектор может быть идеально точным на каждом кадре и выдавать нелепую траекторию

- «Дрожание» рамок
- «Прыжки» координат
- «Колебания» при неподвижном объекте

❏ Детектор не может интерпретировать динамику — это определяющее ограничение в видеозадачах

# Формальные ограничения frame-based подхода

Детектор как статистический оператор:

$$f : \mathbb{R}^{H \times W \times 3} \rightarrow \mathcal{B}$$

Требуемое отображение для видео:

$$F : \mathbb{R}^{T \times H \times W \times 3} \rightarrow \{\mathcal{B}_t\}_{t=1}^T$$

- Нет связи между  $f(I_t)$  и  $f(I_{t+1})$
- Нет механизма проверки согласованности предсказаний
- Нет способа учитывать скрытое состояние объекта
- Нет возможности компенсировать временной шум

Аналогия: фильтрация временного сигнала скользящим окном ширины один

# Потеря стабильности: NMS

## Non-Maximum Suppression

Процедура удаления перекрывающихся боксов по локальным максимумам confidence

$$NMS(\{(b_i, c_i)\})$$

Чувствительность к малейшим изменениям confidence приводит к:

- «Выпрыгивающим» боксам
- «Исчезающим» рамкам
- Конкуренции близких объектов

## Проблемы

Если объект движется мало, но confidence падает — NMS удаляет рамку

При сближении двух объектов одна рамка отбрасывается

Ложные пропуски нарушают временную когерентность

# Scale jitter и аугментации

## Аугментация при обучении

Масштаб, яркость, контраст, геометрия повышают обобщающую способность

## Зависимость от шума

$b_t = f(I_t + \epsilon_t)$ , где  $\epsilon_t$  — малая добавка из-за экспозиции или масштаба

## Побочный эффект

Детектор становится избыточно чувствительным к локальным изменениям текстуры и формы

## Нестабильность

При больших пространственных искажениях высокая чувствительность к  $\epsilon_t$  усиливает нестабильность во времени



# VFR и дроп-фреймы

## Variable Frame Rate

Неравномерные интервалы времени между кадрами

Скорость движения в пикселях становится непредсказуемой

$$b_{t+1} \approx f(I_{t+1})$$

с сильным смещением относительно  $bt$

## Drop-frames

Отсутствие кадров при быстром перемещении объекта

Детектор не может объяснить смещение без истории движения

VFR и drop-frames существенно ухудшают стабильность

# Motion blur и масштаб

## Размытие движения

Интеграция света во время экспозиции

$$I_{blur}(x) = (I * k_v)(x)$$

где  $k_v$  — ядро размытия, зависящее от скорости  $v$

## Потеря текстуры

При быстром движении объект становится аморфным

Детектор теряет объект или снижает confidence

## Изменение масштаба

Приближение к камере меняет форму рамки

Задача стабильной детекции усложняется

# Temporal smoothing

Стратегия уменьшения дрожания рамок и мелких ошибок:

$$\hat{b}_t = \alpha b_t + (1 - \alpha) \hat{b}_{t-1}$$

где  $\alpha$  — коэффициент сглаживания

## Преимущества

- Устранение шума
- Сглаживание траекторий
- Простота реализации


## Ограничения

- Не компенсирует пропуски
- Не устраняет дрейф
- Не обрабатывает резкие скачки
- Создаёт задержку в реакциях

Сглаживание не может заменить трекинг, а лишь служит вспомогательным средством


# Накопление ошибок

Ошибка детектора на кадре  $t$  не исчезает, а накапливается




Начальная ошибка

$$b_t = x_t + \delta_t$$




Аддитивный рост

$$\delta_{t+1} = \delta_t + \epsilon_t$$



Сбои ассоциации

Каждое новое состояние опирается на предыдущие результаты




Необходимость трекинга

Переход к трекингу становится неизбежным

# Необходимость ассоциации объектов

Однофреймовые детекторы не могут обеспечивать стабильность во времени



Трекинг — вторая половина системы видеоаналитики, отвечающая за устойчивость и согласованность

# Формализация многообъектного трекинга

MOT — задача восстановления идентичности и траекторий нескольких объектов

$$T = \{\tau_1, \tau_2, \dots, \tau_K\}$$

где каждая траектория:

$$\tau_i = \{(b_{t_1}^i, t_1), (b_{t_2}^i, t_2), \dots\}$$

|                                        |                            |                                                       |
|----------------------------------------|----------------------------|-------------------------------------------------------|
| 01                                     | 02                         | 03                                                    |
| Детекции на кадре                      | Отображение                | Условия                                               |
| $B_t = \{bt_1, bt_2, \dots, bt_{nt}\}$ | $\pi_t: B_t \rightarrow T$ | Непрерывность движения и согласованность идентичности |

# Identity consistency и ID-switch

## Сохранение идентичности

Центральное требование для MOT-систем

Идентификатор объекта должен оставаться неизменным на протяжении всей траектории

Формально:

если  $bt_1$  и  $bt_2$  принадлежат одному объекту, то  $id(bt_1) = id(bt_2)$

## ID-switch

Ошибочное присвоение идентификатора другого объекта существующему треку

Один из самых разрушительных типов ошибок:

- Траектории непригодны для анализа
- Нарушение стабильности системы
- Разрушение последующего анализа движения

# Система tracking-by-detection



## Детектор

Выдаёт набор рамок  $B_t$  на каждом кадре



## Трекер

Ассоциирует рамки с текущими траекториями

Трекер поддерживает множество активных состояний  $X_t = \{x_{t1}, x_{t2}, \dots, x_{tmt}\}$

Координаты и масштаб

Скорость движения

Время последнего наблюдения

Appearance-эмбединги

Предсказание:  $x_{t|t-1i} = F x_{t-1|t-1i}$

Обновление:  $x_{t|ti} = x_{t|t-1i} + K(z_{ti} - H x_{t|t-1i})$



# Траектория как динамическая система

Траектория — реализация скрытого процесса, развивающегося по законам динамики

Скрытое состояние объекта:

$$x_t = (u_t, v_t, s_t, \dot{u}_t, \dot{v}_t, \dot{s}_t)$$

Динамика объекта

$$x_t = Fx_{t-1} + \omega_t$$

$F$  — матрица перехода

$\omega_t$  — шум модели

Наблюдение

$$z_t = Hx_t + \eta_t$$

$H$  — матрица наблюдения

$\eta_t$  — шум измерения

Эта структура позволяет применять фильтр Калмана для минимизации ошибки между истинными и оценёнными состояниями

# Модель движения объекта

Линейная модель движения с постоянной скоростью

Матрица перехода состояния  $F$  ( $6 \times 6$ ) и матрица наблюдения  $H$  ( $3 \times 6$ ) описывают предсказуемое движение объекта между кадрами

## Координаты

$u_t, v_t$  — центр рамки

## Масштаб

$s_t$  — размер объекта

## Скорости

$\dot{u}_t, \dot{v}_t, \dot{s}_t$  — производные

Временной шаг  $\Delta t$  определяет, насколько далеко объект переместится за один кадр

# Фильтр Калмана

Алгоритм оптимальной линейной фильтрации для оценки скрытого состояния системы

1

Предсказание состояния

$$x_t|t-1 = F x_{t-1}|t-1$$

$$P_t|t-1 = F P_{t-1}|t-1 F^T + Q$$

2

Вычисление усиления Калмана

$$K_t = P_t|t-1 H^T (H P_t|t-1 H^T + R)^{-1}$$

3

Обновление состояния

$$x_t|t = x_t|t-1 + K_t(z_t - H x_t|t-1)$$

4

Обновление ковариации

$$P_t|t = (I - K_t H) P_t|t-1$$

Минимизирует среднеквадратичную ошибку, идеально подходит для MOT

# Предсказание и обновление

## Компенсация пропусков

Если детектор пропустил объект, фильтр Калмана продолжает предсказывать его положение

Опора на модель движения позволяет временно компенсировать исчезновения или краткие окклюзии

## Коррекция смещений

Если детектор выдал сильно смещённую рамку, обновление исправит оценку

Взвешивание наблюдения и предсказания в соответствии с ковариациями  $Q$  и  $R$

❏ Если детектор стабилен — вес наблюдений высок; если детектор шумит — вес предсказания модели возрастает

# Ковариации и шум



## Шум модели (Q)

Определяет доверие к модели движения

Высокое Q → высокая неопределённость движения

Для людей: выше (непредсказуемое движение)

Для автомобилей: ниже (гладкое движение)



## Шум измерений (R)

Определяет доверие к детектору

Высокое R → детектор воспринимается как шумный

Обновление наблюдений происходит осторожно

В реальности Q и R подбирают эмпирически для каждого типа объектов

# Метрики расстояния для ассоциации



IoU distance

$$d_{IoU} = 1 - IoU(b_{pred}, b_{det})$$



Mahalanobis distance

$$d_M = (z - Hx)^T S^{-1} (z - Hx)$$

где  $S$  — innovation covariance



Cosine distance

$$d_{cos} = 1 - \frac{e_1 \cdot e_2}{|e_1| |e_2|}$$

для appearance-эмбедингов

Ассоциация — задача минимизации общей стоимости сопоставления

# Алгоритмы сопоставления

Имея динамическую модель и набор детекций, трекер должен принять решение о соответствии



Современные системы: DeepSORT, OC-SORT, ByteTrack объединяют все эти подходы

# IoU matching

Самая простая форма сопоставления использует геометрию рамок

Матрица IoU matching:

$$M_{ij} = IoU(\hat{b}_t^i, b_t^j)$$

где IoU — мера пересечения двух прямоугольников:

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

## Эффективность

Работает при медленном или умеренном движении объектов

## Ограничения

- Быстрые перемещения
- Изменения масштаба
- Кратковременные пропуски
- Плотные сцены с перекрытиями

IoU matching — основа большинства трекеров, но недостаточен для устойчивой ассоциации



# Венгерский алгоритм

Задача поиска оптимального соответствия между предсказанными состояниями треков и новыми детекциями

Матрица стоимостей  $C \in \mathbb{R}^{m_t \times n_t}$ , где  $C_{ij}$  — стоимость сопоставления трека  $i$  с детекцией  $j$

Задача минимизации:

$$\sigma^* = \arg \min_{\sigma \in \mathcal{P}} \sum_{i=1}^{m_t} C_{i, \sigma(i)}$$

$O(n^3)$

Сложность

Глобально оптимальное решение

3

Компоненты

IoU, Mahalanobis, appearance

Если IoU близок к нулю, стоимость становится высокой, предотвращая некорректные сопоставления

# Матрица matching cost

Общая стоимость сопоставления включает несколько компонент:

$$C_{ij} = \lambda_{IoU} d_{IoU}(i, j) + \lambda_M d_M(i, j) + \lambda_{app} d_{app}(i, j)$$

Геометрия  
 $d_{IoU} = 1 - IoU(\hat{b}_i, b_j)$



Динамика

$d_M$  через фильтр Калмана

Визуальный образ

$d_{app} = 1 - \cos(e_i, e_j)$

Введение appearance-признаков сделало трекинг надёжнее при длительных окклюзиях и пересечениях траекторий

# Appearance embedding

Вектор признаков, описывающий визуальные свойства объекта

Извлечение эмбединга:

$$e = E(I_t[b])$$

где  $E$  — feature extractor,  $I_t[b]$  — вырезанный регион изображения

## Инвариантность

К небольшим изменениям позы и масштаба

## Устойчивость

К различиям освещения

## Дискриминативность

Отличает разные объекты

## Согласованность

Узнаёт объект на новой позиции

Размерность: от 64 до 512. Эмбединги становятся частью состояния трека

# Обучение ReID-эмбеддингов

Appearance embedding обучаются в парадигме person re-identification

Triplet loss:

$$\mathcal{L} = \max(0, |e_a - e_p|^2 - |e_a - e_n|^2 + \alpha)$$

## Компоненты

- $e_a$  — anchor
- $e_p$  — positive (тот же объект)
- $e_n$  — negative (другой объект)
- $\alpha$  — margin

## Дополнительно

Softmax-классификация по ID через cross-entropy

Комбинированная потеря даёт устойчивые эмбеддинги

Успех в person tracking привёл к адаптации для автомобилей, животных, дронов

# Многомодальные признаки

Современные трекеры объединяют motion + appearance

$$C_{ij} = \lambda_m d_M(i, j) + \lambda_a d_{app}(i, j)$$

Предсказанные координаты

Motion-информация из фильтра Калмана

Визуальные признаки

Appearance-эмбединги из ReID-сети

Комбинация motion и appearance снижает количество ID-switch: даже при пересечении объектов их внешний вид остаётся разным

Это привело к появлению DeepSORT — первой массовой системы с ReID-признаками

# DeepSORT

## Расширение SORT

- Appearance embedding
- Глубокая сверточная сеть для ReID
- Двойная компонента matching cost

Трек обновляется при прохождении порога по appearance distance

## Ограничения

- Сильная зависимость от качества ReID-сети
- Плохая работа при быстрых движениях
- Потеря эффективности при низком FPS
- Необходимость новых подходов

# OC-SORT

Ключевое расширение motion-модели: использование оптического потока

Вместо линейной модели Калмана — информация о локальном движении пикселей

Обновление центра рамки:

$$(u_{t|t-1}, v_{t|t-1}) = (u_{t-1}, v_{t-1}) + \frac{1}{|A|} \sum_{(x,y) \in A} v(x, y)$$

где  $v(x,y)$  — поле оптического потока,  $A$  — область объекта

Устойчивость

К быстрым перемещениям

Нелинейная динамика

Учёт сложных траекторий

Оптический поток

Локальная информация о движении

# ByteTrack

Радикальная идея: низкоуверенные детекции можно не отбрасывать, а использовать в ассоциации

Разделение детекций:

$$B_t = B_t^{high} \cup B_t^{low}$$



## Первая ассоциация

Сопоставление треков с  $B_{high}$



## Вторая ассоциация

Оставшиеся треки с  $B_{low}$  по  
низкому порогу



## Восстановление

Устранение flicker-эффекта

ByteTrack стал стандартом промышленного трекинга благодаря устойчивости и простоте



# Современные трекеры 2023–2025



## ByteTrack

Низкоуверенные боксы, двойная ассоциация, высокая устойчивость



## OC-SORT

Оптический поток, продвинутая motion-модель



## BoT-SORT

Сильные ReID-эмбединги и улучшенный matching



## DeepOC-SORT и HybridSORT

Объединение motion, appearance и deep-cost моделей

Эти системы объединяют геометрию, динамику, визуальные признаки, оптический поток и умные стратегии ассоциации

# Ошибки трекинга

Качество MOT невозможно оценивать как обычную детекцию — ошибки имеют динамическую природу

## FN (False Negative)

Объект присутствует в  $G_t$ , но отсутствует в  $P_t$

## FP (False Positive)

Объект отсутствует в  $G_t$ , но присутствует в  $P_t$

## ID-switch

Объект был связан с определённым ID, но на кадре  $t$  ему присвоен другой ID

❏ ID-switch — уникальная ошибка трекинга, разрывающая временную целостность: траектория разделяется на две части

# MOTA и MOTP

## MOTA

Multiple Object Tracking Accuracy

$$MOTA = 1 - \frac{\sum_t (FN_t + FP_t + IDSW_t)}{\sum_t |G_t|}$$

Объединяет все типы ошибок детекции и идентичности

FN, FP и ID-switch суммируются с одинаковым весом

Стали фундаментом ранних систем трекинга, но имеют принципиальные ограничения

## MOTP

Multiple Object Tracking Precision

$$MOTP = \frac{\sum_{t,i} IoU(g_t^i, p_t^{\pi(i)})}{\sum_t |TP_t|}$$

Измеряет точность локализации рамок

# Ограничения MOTA

## → Перекос в сторону детекции

ID-switch и FN считаются одинаковыми ошибками, хотя их влияние различно

## → Зависимость от детектора

Трекер поверх сильного детектора получает преимущество независимо от логики ассоциации

## → Игнорирование качества ассоциации

Не различает непрерывный трек от множества коротких сегментов

## → Неадекватность в плотных сценах

Любая потеря объекта немедленно ухудшает MOTA

Современные исследования опираются на метрики, фокусирующиеся на идентичности — IDF1

# IDF1

Метрика для оценки качества сохранения идентичности

$$IDF1 = \frac{2 \cdot IDTP}{2 \cdot IDTP + IDFP + IDFN}$$



Заботится о том, насколько хорошо система связывает моменты времени в единую траекторию

Если трекер верно сопоставляет все моменты движения, но теряет объект на несколько кадров — IDF1 практически не упадёт

# HOTA

Higher Order Tracking Accuracy — современная метрика, объединяющая локализацию, ассоциацию и идентичность

$$HOTA = \sqrt{DetA \cdot AssA}$$

## DetA

Accuracy детекции — насколько точно рамки соответствуют объектам

## AssA

Accuracy ассоциации — среднее количество корректных сопоставлений по всей траектории

HOTA стала стандартом для оценки MOT после 2020 года, отражая реальную сложность трекинга на всех уровнях ошибки

# Разделение компонентов качества

NOTA впервые дала численные показатели для трёх компонентов:

## LocA

Локализационная точность —  
насколько точно рамки  
соответствуют объектам

## AssA

Корректность ассоциации —  
насколько корректно сопоставлены  
треки

## StA

Стабильность ID — насколько  
равномерно поддерживается  
идентичность во времени


Раздельный подход позволяет обнаруживать слабые места: motion matching, ReID-эмбединги или специфичные ситуации (окклюзии)

# Влияние FPS и пропусков

Частота кадров играет ключевую роль в устойчивости трекинга

Смещение между кадрами:

$$\Delta x = \frac{v}{FPS}$$



Drop-frames: если пропущены  $k$  кадров, смещение становится в  $k$  раз больше. Предсказание Калмана становится бесполезным



# Drift, fragmentation, lost tracks

## Drift (дрейф)

Накопление ошибки в предсказании:

$$\delta_{t+1} = \delta_t + \epsilon_t$$

## Fragmentation (фрагментация)

Разрыв траектории из-за неполной или нестабильной ассоциации

## Lost track (потеря трека)

Трекер прекращает отслеживание объекта, хотя он физически присутствует

Все эти явления ухудшают НОТА и особенно AssA. Часто проявляются при пересечениях, быстром входе/выходе из кадра, частичных перекрытиях

# Оценка на реальных видео

Реальные видео редко имеют идеальные условия

## Сложности

- Размытость
- Сложные тени
- Непредсказуемая геометрия
- Движение камеры
- Перекрытия

## Метрики оценки


- NOTA
- IDF1
- MOTA
- Число ID-switch
- Число фрагментов

Инженеры анализируют траектории по классам объектов и критическим зонам: пересечениям, коридорам, дверям, зонам с большим количеством людей

Такой анализ выявляет слабые места motion-модели, ReID-сети и ассоциации

# Заключение

Видеодетекция и многообъектный трекинг — сложная пространственно-временная задача, требующая:



Современные трекеры объединяют геометрию, динамику, визуальные признаки и оптимальные алгоритмы сопоставления для достижения устойчивой работы в реальных условиях