

Видеосегментация как временная задача

Переход от статических изображений к видеопотокам меняет саму природу задачи сегментации. Маска становится функцией не только пространства, но и времени.

Отличие video segmentation от image segmentation

Статическая сегментация

Анализирует отдельный кадр как завершённый двумерный массив. Решение не зависит от других кадров.

Видеосегментация

Существует в пространстве с временной осью. Маска — функция координат и времени: $M(x, y, t)$.

Ключевое требование

Согласованность во времени, учёт движения, непрерывность формы и сохранение идентичности объектов.

Видеосегментация — это построение непрерывной трёхмерной гиперповерхности, где маска изменяется гладко по оси времени.

Временная когерентность и мерцание

Временная когерентность

Согласованность масок между соседними кадрами. Маска должна плавно трансформироваться при плавном движении объекта.

Покадровые сегментаторы не имеют механизмов отслеживания движения и склонны к мерцанию.

Природа мерцания

Границы объекта на кадрах t и $t+1$ могут измениться значительно при минимальных визуальных различиях.

Причина: модель минимизирует ошибку только в пространственной области, не учитывая временную связь.

Маска как динамическая поверхность

Маску можно понимать как динамическую поверхность на трёхмерном многообразии. Множество точек маски:

$$S = \{(x, y, t) \in \Omega \times \mathbb{R} \mid M(x, y, t) = 1\}$$

Эволюция маски рассматривается как решение задачи минимизации функционала энергии:

$$E[M] = \int_{\Omega \times \mathbb{R}} (\lambda_1 |\nabla_{x,y} M|^2 + \lambda_2 |\partial_t M|^2) dx dy dt$$

Первый член контролирует гладкость границ, второй — гладкость во времени. Покадровая сегментация минимизирует только пространственный член.

Формальная постановка задачи

Видеосегментация — функция F , сопоставляющая видео $X = \{I_1, I_2, \dots, I_T\}$ набору масок $M = \{M_1, M_2, \dots, M_T\}$:

$$M_t = F(I_1, I_2, \dots, I_t)$$

Semi-supervised VOS

Доступна маска на первом кадре M_1 , задача — распространение вперёд.

Unsupervised VOS

Маска определяется внутренней динамикой сцены.

Instance-level

Маски согласованы по объектам и идентичностям.

Ограничения покадровой сегментации



Отсутствие временной памяти

Каждый кадр рассматривается независимо, движение не используется как признак.



Ошибка согласования идентичности

При пересечении объектов маска может «перепрыгнуть» на другой объект.



Нестабильность границ

На сложных текстурах маска дрожит, расширяется или сужается.



Неспособность справляться с окклюзиями

При закрытии объекта модель перестаёт его распознавать.

Drift и накопление ошибок

Феномен drift

Накопление ошибок при переносе маски во времени. Каждая небольшая ошибка приводит к постепенному смещению границ.

Особенно заметно при использовании оптического потока и warping масок.

Последствия

Если на каждом шаге warping создаёт ошибку в 2 пикселя, через 100 кадров маска окажется далеко от объекта.

Drift также проявляется как постепенная деформация формы маски, разрушая качество в длинных роликах.

❏ Требуется механизмы коррекции: cross-frame attention или модели памяти для компенсации ошибок.

Motion blur и деформации

Motion blur

При быстром движении возникает размытие границ. Покадровые сегментаторы неправильно интерпретируют размытые границы.

Изменение масштаба

Объект приближается или удаляется, изображение растягивается или сжимается. Ошибки в обработке масштаба приводят к дрожанию маски.

Деформации

Изменение ракурса или изгибы объекта усложняют сегментацию, меняя форму границ и визуальный контекст.

Проблема VFR и дроп-фреймов

В промышленной обработке видео часто встречаются потоки с переменной частотой кадров (VFR). Временные интервалы между кадрами неравномерны.

Влияние VFR

Если два кадра сняты с большой паузой, скорость объекта в модели должна увеличиться для компенсации движения.

Покадровая сегментация не знает длительности Δt между кадрами.

Дроп-фреймы

Отсутствие нескольких кадров разрушает временную структуру. Модель теряет последовательность движения.

Объект может исчезнуть и появиться значительно смещённым.

Маска как вероятностное поле

Современные модели рассматривают маску как вероятностное поле, отражающее степень уверенности в принадлежности пикселя объекту.

Перенос вероятностной маски:

$$M_{t+1}(x) = M_t(x - v(x))$$

где $v(x)$ — оптический поток. Для компенсации искажений используются фильтры по времени:

$$\tilde{M}_{t+1} = \alpha M_{t+1} + (1 - \alpha) \hat{M}_{t+1}$$

где $\hat{M}_{t+1}$ — предсказанная свежая маска, α — коэффициент сглаживания. Усреднение уменьшает случайные колебания и повышает когерентность.

Переход к методам переноса масок

1

Оптический поток

Моделирует движение каждого пикселя, позволяет корректно переносить форму объекта.

2

Ограничения потока

Ошибки на границах, в зонах окклюзий и при быстром движении.

3

Attention между кадрами

Извлекает информацию напрямую из соседних изображений, где поток не работает.

Перенос масок: optical flow, warping и temporal propagation

Оптический поток остаётся фундаментальной аппроксимацией движения объектов и сцены в видеосегментации.

Оптический поток как аппроксимация движения

Идеологическая база оптического потока — предположение о сохранении интенсивности пикселя вдоль траектории движения:

$$I(x, t) = I(x + v(x), t + \Delta t)$$

Для малых Δt переходит в дифференциальное уравнение:

$$\nabla I \cdot v + I_t = 0$$

где ∇I — пространственный градиент, v — вектор потока, I_t — временная производная.

❏ Качество потока определяет качество warping маски. Ошибки в потоке приводят к drift и деформациям.

Математическая модель optical flow

Задача поиска $v(x)$, минимизирующего функционал:

$$E(v) = \int_{\Omega} (I(x, t) - I(x + v(x), t + 1))^2 dx + \lambda \int_{\Omega} |\nabla v(x)|^2 dx$$

Data term

Первый член выражает расхождение яркостей между кадрами.

Smoothness term

Второй член контролирует гладкость поля движения.

Современные методы (PWC-Net, RAFT, GMFlow) решают задачу с помощью сверточных или трансформерных архитектур.

Bilinear warping и перенос маски

Перенос маски через оптический поток реализуется посредством bilinear warping:

$$M_{t+1}(x) = M_t(x - v(x))$$

где $v(x)$ — поток от кадра t к кадру $t + 1$.

```
import torch
import torch.nn.functional as F

def warp_mask(mask, flow):
    B, _, H, W = mask.shape
    y, x = torch.meshgrid(
        torch.linspace(-1, 1, H, device=mask.device),
        torch.linspace(-1, 1, W, device=mask.device),
        indexing='ij'
    )
    grid = torch.stack((x, y), dim=-1).unsqueeze(0).repeat(B, 1, 1, 1)

    flow_norm = torch.zeros_like(flow)
    flow_norm[:, 0] = flow[:, 0] / (W / 2)
    flow_norm[:, 1] = flow[:, 1] / (H / 2)

    warped_grid = grid + flow_norm.permute(0, 2, 3, 1)
    warped_mask = F.grid_sample(mask, warped_grid, align_corners=True)
    return warped_mask
```

Ошибки оптического потока



Occlusion

Часть объекта закрывается другим объектом или выходит за пределы кадра. Метод пытается найти соответствие, создавая ложное движение.



Hallucination

Модель «придумывает» движение при размытых границах, тенях, бликах или повторяющихся текстурах.

В зонах низкого градиента ∇I оптическое уравнение плохо обусловлено. Ошибки на контуре объекта деформируют маску.

Drift при последовательном warping

Накопление ошибок потока при многократном повторении warping. Если ошибка потока e_t на шаге t не нулевая, накопленная ошибка после n шагов:

$$E_n = \sum_{t=1}^n e_t$$

Несистематичная ошибка

Drift выглядит как случайное плавание границ маски.

Систематичная ошибка

Drift накапливается линейно, маска полностью теряет связь с объектом.

❏ Optical flow не может быть единственным механизмом. Требуются attention или memory-архитектуры.

Propagation в вероятностных масках

Перенос вероятностей вместо бинарных значений делает warping более устойчивым:

$$M_{t+1}^{warp}(x) = M_t(x - v(x))$$

Окончательная маска — комбинация warping-прогноза и нового предсказания:

$$M_{t+1} = \alpha M_{t+1}^{warp} + (1 - \alpha) \hat{M}_{t+1}$$

где α контролирует вклад переноса. Формула выступает как фильтр Калмана: перенесённая маска — предсказание, свежая маска — измерение.

Сглаживание уменьшает мерцание, удерживая маску близко к истинному положению объекта.

Temporal smoothing: фильтрация масок

Временная фильтрация — важнейший этап стабилизации. Простейший метод — экспоненциальное сглаживание:

$$M_t^{smooth} = \beta M_t + (1 - \beta) M_{t-1}^{smooth}$$

Более продвинутые методы используют вариационные принципы, минимизируя энергию:

$$E = \int (|\nabla M_t|^2 + \gamma |M_t - M_{t-1}|^2) dx$$

Минимизация приводит к маске, одновременно гладкой в пространстве и согласованной во времени.

CRF, графы, энергетические функционалы

До deep learning методы видеосегментации опирались на CRF-модели и энергетические методы. Сегодня применяются как регуляризующие методы поверх предсказаний сетей.

Энергетический функционал:

$$E(M_t) = \int (w_1 |\nabla M_t|^2 + w_2 |M_t - W(M_{t-1})|^2) dx$$

где W — операция warping. Решение вычисляется градиентным спуском или итеративными методами.

❏ Энергетические методы полезны при требовании экстремально высокой стабильности масок.

Инженерные проблемы propagation

01

Сложность при больших разрешениях

Операции warping требуют dense flow и dense mask, что при больших $H \times W$ приводит к высокой вычислительной стоимости.

02

Риск накопления ошибок

Особенно критично при длинных последовательностях.

03

Чувствительность к шуму

Propagation требует точной модели потока для текущей сцены.

04

Масштабирование на 4K

Используются методы downsampling/upscaling с потерей точности на границах.

Переход к attention-методам

Оптический поток и propagation ограничены локальными соответствиями пикселей. Появление attention-моделей изменило ситуацию кардинально.

1

Cross-frame attention

Извлекает информацию напрямую из соседних кадров через сопоставление признаков.

2

Несколько опорных кадров

Резко снижает риск drift, работает даже при ошибках потока.

3

Глобальные операции

Переход от локального переноса к сопоставлению ключей и значений.

Cross-Frame Attention и пространственно-временная память

Attention между кадрами не аппроксимирует движение напрямую. Он строит сопоставление между признаковыми векторами на высоком уровне абстракции.

Мотивация перехода к attention

Ограничения потока

Поток хорошо работает при гладком движении без окклюзий. На сложных сценах становится шумным, предсказания дрейфуют.

Парадокс: чем длиннее наблюдаем объект, тем менее точной становится маска.

Преимущества attention

Сопоставляет признаки, учитывая подобие текстур, контуров, частей объектов и глобальных структур.

Устойчив к motion blur, быстрым перемещениям, окклюзиям, изменению масштаба.

Attention может «прыгать через воздух»: находить соответствующие области даже если пиксельные координаты не совпадают.

Формализация cross-frame attention

Query формируются из текущего кадра, key/value — из предыдущих кадров. Пусть F_t — признаки текущего кадра, F_s — признаки кадра-источника ($s < t$):

$$A_{ij} = \text{softmax}_j \left(\frac{q_i^\top k_j}{\sqrt{d}} \right)$$

где $q_i = W_Q F_t(i)$, $k_j = W_K F_s(j)$, $v_j = W_V F_s(j)$. Output:

$$o_i = \sum_j A_{ij} v_j$$

Каждый признак текущего кадра выбирает релевантные признаки из других кадров, не полагаясь на точное совпадение координат.

Видео как тензор $T \times H \times W$

Видео — трёхмерный тензор $T \times H \times W$. Attention-трансформеры используют двумерное представление: каждый кадр преобразуется в последовательность токенов длины $N = H \cdot W$.

$$O((T \cdot N)^2)$$

Сложность self-attention

По всем кадрам вычислительно невозможна

$$T \cdot N$$

Размер последовательности

Для видео длиной T кадров

Cross-frame attention ограничивает сопоставление только текущим и опорными кадрами, снижая сложность при сохранении временной агрегации.

Space–Time Attention

Объединяет spatial attention внутри кадра и temporal attention между кадрами:

$$A^{space}(i, j) = \text{softmax} \left(\frac{q_i^\top k_j}{\sqrt{d}} \right), \quad j \in \text{same frame}$$

$$A^{time}(i, j) = \text{softmax} \left(\frac{q_i^\top k_j}{\sqrt{d}} \right), \quad j \in \text{other frames}$$

Комбинированный attention:

$$A_{ij} = \alpha A^{space}(i, j) + (1 - \alpha) A^{time}(i, j)$$

где α контролирует баланс между пространственными и временными связями.

Space-Time Memory Networks (STM)

Первые эффективные модели VOS нового поколения используют память для хранения ключей и значений предыдущих кадров.

01

Запись в память

Каждый кадр вносит пару (key, value), где key — признаки для сопоставления, value — информация о маске.

02

Чтение из памяти

При предсказании маски для кадра t модель извлекает релевантные признаки через attention.

03

Комбинирование

Текущая маска — взвешенная комбинация предыдущих масок в пространстве признаков.

$$m(x) = \sum_j A(x, j) \cdot v_j$$

Модель key-value памяти

На каждом кадре t формируются признаки F_t , маска M_t и вычисляются:

$$k_t = W_k(F_t), \quad v_t = W_v(F_t, M_t)$$

Память представляет собой набор:

$$\mathcal{M} = \{(k_1, v_1), (k_2, v_2), \dots, (k_{t-1}, v_{t-1})\}$$

При новом кадре attention вычисляется как:

$$A_t(i, j) = \text{softmax}_j \left(\frac{k_t(i)^\top k_j}{\sqrt{d}} \right)$$

Итоговый признак:

$$m_t(i) = \sum_j A_t(i, j) v_j$$

Операция чтения из памяти

```
def memory_read(query, keys, values):  
    # query: (B, N, D)  
    # keys: (B, M, D)  
    # values:(B, M, D)  
    attn = torch.softmax(  
        query @ keys.transpose(-1, -2) / (keys.size(-1) ** 0.5),  
        dim=-1  
    )  
    out = attn @ values  
    return out
```

Этот примитив лежит в основе STM, STCN, AOT и многих других современных моделей видеосегментации.

Чтение из памяти позволяет «вспоминать» объект даже после длительных окклюзий или сильных деформаций.

Запись маски в память

Запись происходит когда модель уверена в маске. Маска выделяет признаки именно объекта, а не фона:

$$v_t = F_t \odot M_t$$

где $\odot$ — поканальное умножение. Память становится объектно-ориентированной.


Проблема роста

Память растёт линейно с длиной видео.

Решение

Отбор ключевых кадров: запись на ключевых рамках по движению, уверенности или регулярным интервалам.

Современные VOS-модели 2023–2025



Инженерные оптимизации памяти

Sparse memory

Память хранит только выбранные ключи и значения, уменьшая размер матриц attention.

Key dropout

При записи некоторые ключи отбрасываются, убирая избыточные коррелированные признаки.

Memory pruning

Алгоритмическая очистка памяти после роста.

Формально pruning:

$$\mathcal{M}' = \{(k_j, v_j) \in \mathcal{M} \mid |k_j - \bar{k}| > \delta\}$$

где $\bar{k}$ — средний ключ памяти. Оставляет только наиболее разнообразные ключи, предотвращая memory saturation.

Метрики видеосегментации и инженерная устойчивость

Attention и memory-модели изменили подход к видеосегментации. Перенос масок происходит через извлечение релевантных признаков из истории.

Возникает вопрос: как измерять качество видеосегментации, учитывая комбинацию нескольких механизмов?

Типы ошибок VOS



Drift

Постепенное ускользание маски от истинного положения объекта из-за накопленных ошибок переноса или attention, смещённого на фон.



Collapse

Внезапное разрушение маски: исчезновение объекта или резкое сокращение границ.



Loss of identity

Потеря соответствия объекта, маска начинает описывать другой объект с похожими признаками.

Метрика Jaccard (IoU)

Классическая метрика сегментации — Intersection over Union:

$$J(M_t, G_t) = \frac{|M_t \cap G_t|}{|M_t \cup G_t|}$$

где M_t — предсказанная маска, G_t — истинная маска.

Ограничения IoU

- Не чувствителен к качеству границ
- Не содержит информации о стабильности между кадрами
- Маска может «прыгать», IoU остаётся высоким

Применение

IoU используется как одна из компонент комплексных видеометрик, никогда — как единственная мера качества.

Boundary F-score

Измеряет расстояние между предсказанными и истинными границами. Пусть $B(M)$ — множество точек границы маски M :

$$P = \frac{|B(M) \cap B(G) * \varepsilon|}{|B(M)|}, \quad R = \frac{|B(G) \cap B(M) * \varepsilon|}{|B(G)|}$$

$$F = \frac{2PR}{P + R}$$

Boundary F-score критичен для видеосегментации: небольшие временные колебания границ приводят к визуально заметным артефактам.


❏ Если маска дрожит на границе, IoU может оставаться высоким, а Boundary F-score резко падает.

Метрика J&F в DAVIS


Наиболее распространённая метрика видеосегментации — J&F (DAVIS benchmark):

$$J\&F = \frac{1}{2}(J + F)$$

Сочетает Jaccard и Boundary F-score, измеряя одновременно качество персептивного соответствия и точность границ.



Вклад Jaccard Index



Вклад Boundary F-score

Главное преимущество: усредняется по времени. Нарушение согласованности, мерцание, дрожание масок уменьшают итоговое значение.

Video-mIoU и чувствительность к шуму

Видео-вариант mean IoU:

$$\text{video-mIoU} = \frac{1}{T} \sum_{t=1}^T \text{IoU}(M_t, G_t)$$

Характеристики

Менее чувствителен к колебаниям границ, чем J&F, но сильно подвержен шуму.

Единичный пропуск маски резко снижает mIoU.

Применение

Полезен при анализе robustness модели, но опасен для интерпретации в длинных видео.

Хорошая модель должна минимизировать variance масок между кадрами.

Fail-cases и инженерные политики

Видеосегментационная система должна иметь механизмы защиты от разрушения маски:



TTL (time-to-live)

Маска сохраняется при временной потере уверенности:

$$M_t^{final} = \begin{cases} M_{t-1}, & \text{если } \hat{M}_t < \theta \text{ и TTL} \\ \hat{M}_t, & \text{иначе} \end{cases}$$



Warm-up

Устойчивое начальное состояние.
Аккуратное накопление признаков
в начале видео, когда память пуста.



Reactivation

Восстановление маски через
признаки в памяти, если attention
перепрыгнул на фон.

Эти политики определяют поведение системы в продакшне. Их эффективность измеряется метриками J, F и J&F.