

Временная локализация событий и видео-аномалии

Видео как временной сигнал

Видеопоток — это дискретизация непрерывной функции $V(t) : \mathbb{R} \rightarrow \mathbb{R}^{H \times W \times C}$, где каждый момент связан с соседними физически и семантически.

Кадровый подход

Независимые изображения,
пространственные операции

Временной подход

Непрерывный сигнал, динамика и
эволюция признаков

Ключевое отличие

События не локализуются в одном
кадре

Понятие события и интервала

Событие — непрерывный фрагмент времени с семантическим содержанием:

$$e = [t_{\text{start}}, t_{\text{end}}] \subset \mathbb{R}$$

Латентная реальность

События имеют размытые границы и постепенные переходы между состояниями

Наблюдаемая разметка

Вынужденная аннотация конечными точками времени создаёт фундаментальную неопределённость

Распознавание vs Локализация

1

Распознавание действий

Классификация клипа фиксированной длины:

$$f : \{V(t_k)\}_{k=1}^T \rightarrow c$$

Границы заданы априори

2

Временная локализация

Предсказание классов и границ:

$$f : \{V(t_k)\}_{k=1}^N \rightarrow \{(c_i, [t_i^{\text{start}}, t_i^{\text{end}}])\}_{i=1}^M$$

Границы — латентные переменные

Три уровня представления

Покадровое

Вектор признаков для каждого кадра: $s_k = g(V(t_k))$

Игнорирует длительность состояний

Клиповое

Агрегация соседних кадров:

$$c_i = h(\{V(t_k)\}_{k=i}^{i+T})$$

Фиксированная длина окна

Событийное

Интервалы с семантическим смыслом

Переменная длительность, возможны перекрытия

Полная и слабая разметка

Полная разметка

Точные временные границы для каждого события

- Прямая регрессия границ
- Высокая стоимость аннотации
- Субъективные решения экспертов

Слабая разметка

Только классы событий без границ

- Границы — скрытые переменные
- Требуется специальных архитектур
- Более реалистична для практики

Неопределённость границ

Истинные границы событий — случайные величины:

$$t_{\text{start}}, t_{\text{end}} \sim p(t \mid V)$$

Природа проблемы

Начало и конец событий размыты
во времени, зависят от контекста

Практические проявления

Низкая согласованность между
аннотаторами, разброс в десятки
кадров

Инженерное решение

Допуски по времени, IoU
интервалов, вероятностные
представления

Формальная постановка задачи

Дана временная последовательность признаков $X = \{x_t\}_{t=1}^T$. Требуется найти набор интервалов:

$$\mathcal{E} = \{(c_i, [s_i, e_i])\}_{i=1}^M$$

максимизирующий апостериорную вероятность:

$$p(\mathcal{E} \mid X)$$

📄 **Ключевые аспекты:** число событий M неизвестно, интервалы могут перекрываться, задача является структурным предсказанием

Типовые ошибки постановки



Редукция к покадровой классификации

Пороговое выделение интервалов без учёта длительности приводит к фрагментации



Фиксированные окна

Игнорирование вариативности длительности событий вызывает систематические смещения



Недооценка постобработки

Без явного сглаживания нейросеть не выдаёт чистые интервалы

Связь с временной когерентностью

Временная локализация — логическое продолжение идей когерентности, перенесённое с уровня пикселей на уровень событий.

Сегментация

Согласованность масок между кадрами

Локализация

Согласованность оценок активности во времени

Общий фундамент: фильтрация шума и учёт временной структуры сигнала

Скользящее окно

Простейший метод добавления временного контекста:

$$X_i = \{x_i, x_{i+1}, \dots, x_{i+T-1}\}, \quad s_i = f(X_i)$$

Преимущества

- Интуитивная простота
- Использование готовых моделей
- Параллельная обработка

Фундаментальные ограничения

- Фиксированная длина окна
- Дрожание предсказаний
- Разрыв длинных событий

Временная агрегация признаков

Pooling-операции для компактного представления:

$$z = \text{Pool}(x_1, x_2, \dots, x_T)$$

Средний pooling

Устойчив к шуму, сглаживает сигнал

Максимальный pooling

Чувствителен к всплескам
активности

Temporal attention

Адаптивные веса: $\alpha_t = \frac{\exp(w^\top x_t)}{\sum_k \exp(w^\top x_k)}$

Ограничение: потеря информации о структуре времени после агрегации

Temporal Convolutional Networks

Прямое обобщение одномерных свёрток на временные последовательности:

$$y_t = \sum_{i=0}^{K-1} k_i \cdot x_{t-i}$$

Архитектурные свойства

- Параллельная обработка
- Фиксированное рецептивное поле
- Детерминированность выходов

Применение

- Локальные временные зависимости
- Устойчивые шаблоны активности
- Временные головы над бэкбонами

Дилатированные свёртки

Разреженность во временном измерении для увеличения рецептивного поля:

$$y_t = \sum_{i=0}^{K-1} k_i \cdot x_{t-d \cdot i}$$

01

Коэффициент дилатации d определяет шаг перепрыгивания

02

Стек слоёв с возрастающими дилатациями

03

Экспоненциальный рост рецептивного поля

04

Объединение локальных и длительных зависимостей

Рекуррентные модели: LSTM

Моделирование через скрытое состояние: $h_t = f(x_t, h_{t-1})$

Механизмы LSTM:

$$i_t = \sigma(W_i x_t + U_i h_{t-1})$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1})$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1})$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tanh(W_c x_t + U_c h_{t-1})$$

$$h_t = o_t \odot \tanh(c_t)$$

📄 **ConvLSTM:** замена линейных преобразований на свёртки для сохранения пространственной структуры

Трансформеры для временных последовательностей

Self-attention заменяет рекуррентную обработку:

$$\text{Attn}(Q, K, V) = \text{softmax} \left(\frac{QK^{\top}}{\sqrt{d}} \right) V$$

Преимущества

Прямое взаимодействие любых моментов времени, нет фиксированного рецептивного поля

Ограничения

Квадратичная сложность по длине последовательности T

Решения

Иерархические схемы, разреженное внимание, window-based attention

Self-attention как механизм выделения событий

Матрица внимания выявляет взаимосвязи между моментами времени:

$$A_{ij} = \frac{q_i^\top k_j}{\sqrt{d}}$$

Внутри события

Плотное внимание, высокие значения A_{ij}

Между событиями

Разреженное внимание, низкие значения

Начало и конец проявляются как изменения структуры attention-карт

Ограничения по длине последовательности

90K

Временных шагов

В одном часе видео при 25 FPS

$O(T^2)$

Сложность

Self-attention по длине последовательности

Решения: иерархические схемы, предварительная агрегация признаков, клиповые эмбединги с шагом

TSCN vs Трансформеры

Temporal Convolutional Networks

- Простота и стабильность
- Контроль латентности
- Локальная обработка
- Детерминированность

Трансформеры

- Высокая выразительность
- Глобальный контекст
- Гибкость зависимостей
- Вычислительная сложность

Гибридный подход: TCN для локальной обработки + трансформер для глобальной агрегации

Интеграция с видеобэкбонами

1

Видеобэкбон

Извлечение пространственных
визуальных признаков из кадров

2

Временная голова

TCN / LSTM / Трансформер для
моделирования динамики

3

Выходной слой

Оценки активности и границ событий

Конвейеры временной локализации

Временная локализация — это не модель, а инженерный процесс, где нейросеть является лишь одним из компонентов.

Ключевое различие: это не классификация скользящих окон, не временная регуляризация пространственных предсказаний, а анализ структуры событий во времени.

Извлечение временных признаков

Видеопоток проходит через бэкбон:

$$V(t) \longrightarrow X = \{x_1, x_2, \dots, x_T\}, \quad x_t \in \mathbb{R}^d$$

Необратимое решение

Пространственная структура схлопывается в компактный эмбединг

Параметры задачи

Stride по времени и длина клипа определяют возможность восстановления границ

Если событие не оставило след в признаках, оно не может быть восстановлено позже

Оценки активности как временной сигнал

Временная модель формирует оценки:

$$s_t = f_{\text{temp}}(x_t)$$

где s_t — дискретная аппроксимация латентной непрерывной функции активности $a(t) \in [0, 1]$

❏ **Критическая ошибка:** рассматривать $\{s_t\}$ как независимые вероятности. В действительности это временной сигнал с корреляцией, инерцией и шумом.

Выход временной модели — сырьё для дальнейших преобразований, а не финальный ответ

Одностадийная локализация

Прямое отображение признаков в события:

$$f : \{x_t\}_{t=1}^T \longrightarrow \{(c_i, \hat{s}_i, \hat{e}_i)\}_{i=1}^M$$

Концептуальная проблема

Модель должна по локальному контексту определить глобальную структуру события

Практические последствия

Высокая чувствительность к шуму, необходимость агрессивного сглаживания

Двухстадийный подход

Генерация кандидатных интервалов с последующей классификацией:

$$\mathcal{P} = \{[s_i, e_i]\}_{i=1}^K$$

01

Формирование множества временных предложений

02

Классификация каждого кандидата

03

Фильтрация и уточнение границ

04

Подавление дубликатов (Temporal NMS)

Преимущество: задача становится отбором структур, а не регрессией

Регрессия границ

Предсказание смещений относительно опорных точек:

$$\hat{s} = t - \Delta t_s, \quad \hat{e} = t + \Delta t_e$$

Ошибка начала

Влияет на перекрытие интервалов и IoU

Ошибка конца

Искажает длительность события

Проблема: сырые предсказания имеют высокую дисперсию, особенно на границах с плавным изменением сигнала

Перекрывающиеся события

Реальные видеопотоки содержат интервалы с пересечениями:

$$[s_i, e_i] \cap [s_j, e_j] \neq \emptyset$$

Нормальный режим

События часто перекрываются или образуют вложенные структуры

Проблема наивных подходов

Пороговое выделение не различает перекрытия

Решение

Многоканальные представления или независимые потоки предложений

Temporal NMS

Подавление немаксимумов на основе IoU интервалов:

$$\text{IoU} = \frac{|[s_1, e_1] \cap [s_2, e_2]|}{|[s_1, e_1] \cup [s_2, e_2]|}$$

Необходимость

Устранение дублирующих
предсказаний

Опасность

Жёсткое подавление уничтожает
вложенные интервалы и мелкие
события

Практика

Мягкие варианты подавления,
многоуровневая фильтрация

От сигнала к интервалам

Весь конвейер как отображение:

$$\{s_t\}_{t=1}^T \longrightarrow \{[s_i, e_i]\}_{i=1}^M$$



Недифференцируемость

Включает пороговые операции,
объединение сегментов,
фильтрацию



Индуктивные предположения

Здесь закладывается
определение того, что считать
событием



Ручная настройка

Параметры связаны с FPS,
латентностью и требованиями
приложения

Связь с метриками

Временная локализация — не покадровая задача. Качество оценивается через:




Совпадение интервалов

Степень перекрытия предсказанных и истинных событий



Устойчивость границ

Стабильность предсказаний начала и конца



Корректность структуры

Правильное представление перекрытий и вложенностей

Метрики и видео-аномалии

Оценка качества временной локализации требует специальных метрик, учитывающих событийную природу задачи.

Почему покадровая точность неприменима

Объект предсказания — временной интервал, а не момент времени

Ошибка подхода

Покадровая точность оценивает совпадение индикаторных функций $1_{t \in I^*}$ и $1_{t \in I}$

Что теряется

Не различает систематический сдвиг границ, переоценку длительности и фрагментацию

Последствия

Не коррелирует с качеством локализации, непригодна для обучения и валидации

Временная IoU

Базовая мера совпадения интервалов:

$$\text{IoU}(I_1, I_2) = \frac{\max(0, \min(e_1, e_2) - \max(s_1, s_2))}{\max(e_1, e_2) - \min(s_1, s_2)}$$

Чувствительность

Одновременно учитывает сдвиг начала, сдвиг конца и ошибку длительности

Масштабирование

Автоматически ужесточает требования для коротких событий

Естественность

Соответствует интуитивному пониманию качества локализации

mean Average Precision (mAP)

Интегральная метрика по набору порогов IoU: $\tau \in \{0.3, 0.5, 0.7\}$

01

Для каждого порога τ определяется корректность:

$$\text{IoU}(I, I^*) \geq \tau$$

03

Вычисление средней точности для данного порога

02

Построение precision-recall кривой по уверенности предсказаний

04

Усреднение по классам и всем значениям τ

Ошибки границ

Доминирующий источник деградации mAP:

$$\delta_s = s - s^*, \quad \delta_e = e - e^*$$

Систематический характер

Связаны с архитектурой временной модели и постобработкой

Нелинейное влияние

Малые ошибки резко снижают IoU для коротких событий

Вывод: оптимизация границ — центральная проблема, а не второстепенная задача

Видео-аномалии

Предельный случай временной локализации без явного класса события

1

Нормальное поведение

Модель обучается на нормальных данных

2

Функция отклонения

Сигнал $d(t)$ превышает допустимый уровень

3

Интервалы аномалий

Выделение $I = [s, e]$ с высоким отклонением

Изоморфна задаче локализации событий, но с другим источником сигнала активности

Реконструктивные и предсказательные модели

Реконструктивные

Ошибка восстановления нормальных признаков:

$$r_t = \|x_t - \hat{x}_t\|$$

Устойчивы к шуму

В обоих случаях $\{r_t\}$ — временной сигнал, требующий преобразования в интервалы

Предсказательные

Ошибка предсказания будущего:

$$r_t = \|x_{t+1} - \hat{x}_{t+1}\|$$

Чувствительны к всплескам

Сглаживание временных сигналов

Свёртка с ядром для снижения шума:

$$\tilde{s}_t = \sum_{k=-K}^K w_k s_{t+k}$$



Устойчивость

Снижение дисперсии сигнала



Смещение границ

Систематический сдвиг начала и конца

Компромисс: сглаживание должно рассматриваться как часть модели, параметры подбираются совместно с дискретизацией

Пороговые стратегии

Переход от сигнала к интервалам через условие:

$$\tilde{s}_t \geq \theta$$

Фиксированный порог

Прост, но нестабилен при изменении условий съёмки и домена

Адаптивный порог

Основан на статистике сигнала, повышает устойчивость, усложняет интерпретацию

Пороговое выделение — дискретизирующая операция, определяющая форму интервалов

Инженерная интеграция

Временная локализация в реальных системах работает в условиях:

Ограниченная латентность

Онлайновый режим, недоступность
будущего, причинные фильтры

Неполные данные

Пропуски кадров, VFR,
рассинхронизация таймстемпов

Нестабильный FPS

Систематический сдвиг границ,
невозможность компенсации
постфактум

Заключение: архитектурные и метрические решения неотделимы от инженерных ограничений